

Guía de defensa - Presentación EP1

StreamView Analytics | ADY1104 Visualización de Datos | Claudio Aro, Guillermo Cerda, Manuel Díaz

Cómo usar esta guía

La nota es individual y el docente puede hacer preguntas cruzadas: **los tres integrantes deben dominar todo el contenido**, no solo sus diapositivas.

Tiempo: 10 minutos de exposición + 5 de preguntas. Ensayar con cronómetro al menos dos veces. Si se hace la demo en vivo, recortar 30 s en otras diapositivas.

Regla de oro al responder: dato + significado + decisión ("el 62% de las series tiene menos de 10 votos, eso significa que no se descubren, por eso proponemos...").

1. Distribución de la exposición

Integrante	Diapositivas	Tiempo	Contenido
Claudio Aro	1 a 5	3:00	Presentación, problema de negocio, audiencia y propósito, estrategia de comunicación, metodología CRISP-DM, fuentes e integración de datos
Guillermo Cerda	6 a 11	3:40	Concentración, índice de tracción, joyas ocultas, idiomas, tendencia y ROI, justificación técnica de los gráficos
Manuel Díaz	12 a 16	3:00	Idea central, dashboard, recomendaciones con evidencia, evaluación crítica, cierre

El guion completo de cada diapositiva está en las notas del orador del archivo PowerPoint.

2. Cifras que todos deben saber de memoria

Cifra	Qué significa
31.991 títulos, 2010-2025, 83 idiomas	Tamaño del catálogo integrado (16.000 películas y 15.991 series)
71% / 86%	Votos que concentra el 10% de títulos más votados (películas / series)
62%	Series con menos de 10 votos (baja visibilidad)
x2,5 / x0,1	Tracción de ciencia ficción y fantasía / reality, talk show, noticias (series)
54% vs 26%	Documentales de película con nota 7+ vs total de películas
52% vs 21%	Películas japonesas vs en inglés con nota 7+
0,23 / 0,17	Correlación de Spearman popularidad-calificación (películas / series)
-17%	ROI mediano de películas de 2020 (antes ~100%, hoy 61%)
20% a 28% / 56% a 71%	Películas / series bien evaluadas, 2010 a 2024

3. Preguntas probables por indicador de la pauta

IE1 - Audiencia objetivo

P: ¿Quién es su audiencia y por qué?

R: La audiencia primaria es el directorio y la gerencia general, que decide con poco tiempo y sin perfil técnico. Hay tres audiencias secundarias: contenidos y adquisiciones, producto y experiencia de

usuario, y el equipo de analítica. Por eso hicimos dos productos: una narrativa ejecutiva y un dashboard exploratorio.

P: ¿Cómo adaptaron la solución a esa audiencia?

R: Pirámide invertida (conclusión primero), un solo mensaje por diapositiva, lenguaje de negocio ("joyas ocultas", "tracción") en vez de términos estadísticos, y metas medibles. El detalle técnico queda en el informe, los notebooks y la página de metodología.

IE2 - Propósito comunicacional

P: ¿Cuál es el propósito comunicacional?

R: Persuadir a la gerencia para aprobar tres decisiones (exponer las joyas ocultas, reorientar la adquisición y medir comportamiento real) e informar a las gerencias operativas mediante el dashboard. Se conecta con el negocio porque el contenido no descubierto reduce el valor percibido y pone en riesgo la retención de suscriptores.

IE3 - Estrategia de comunicación

P: ¿Por qué eligieron una estructura de storytelling en tres actos?

R: Contexto, conflicto y resolución generan tensión y la resuelven con acciones concretas; eso facilita que una audiencia ejecutiva recuerde el mensaje y tome una decisión. La idea central actúa como hilo conductor.

P: ¿Qué alternativas de estrategia descartaron?

R: El relato cronológico del análisis, porque entierra la conclusión al final; un único dashboard para todos, porque sobrecarga a la gerencia y no sostiene un argumento; y la jerga estadística en el mensaje principal, porque aleja a la audiencia primaria. Está en la diapositiva 3 y en la Tabla de estrategia del informe.

P: ¿Por qué títulos-mensaje?

R: Porque reducen la carga cognitiva: el lector no tiene que deducir la conclusión del gráfico; el título ya la dice y el gráfico la demuestra.

Metodología CRISP-DM

P: ¿Qué metodología siguieron?

R: CRISP-DM, en seis fases: comprensión del negocio (problema, 8 preguntas, audiencias), comprensión de los datos (2 fuentes, diagnóstico de calidad, origen TMDB), preparación (limpieza, 21 géneros, 31.991 títulos), modelado (indicadores descriptivos: calificación ponderada, tracción, Lorenz, cuadrantes), evaluación (76 cifras verificadas, robustez) y despliegue (dashboard, informe, presentación).

P: Si no hay modelo predictivo, ¿qué es el modelado?

R: Un modelado analítico-descriptivo: construimos indicadores y segmentaciones y elegimos la codificación visual. El objetivo era explicar y comunicar, no predecir, y así lo declaramos en el informe.

P: ¿Dónde se ve que CRISP-DM es iterativo?

R: Tres ejemplos: las notas 0 sin votos nos hicieron volver a la preparación; los promedios engañosos por género, al modelado (calificación ponderada); y descubrir que los votos vienen de TMDB nos hizo volver al negocio para redefinir las metas con reproducciones propias.

IE8 - Justificación técnica de las representaciones

P: ¿Por qué una curva de Lorenz y no un gráfico de barras?

R: Con 16.000 títulos por tipo, las barras serían ilegibles. La curva de Lorenz es la representación estándar de concentración: la distancia a la diagonal muestra la desigualdad.

P: ¿Por qué una matriz de burbujas en escala logarítmica?

R: Relaciona tres variables (tracción, calificación y cantidad de títulos) y los cuadrantes convierten el dato en acción. La escala log es necesaria porque la tracción va de 0,06 a 2,5; en escala lineal los géneros de baja tracción quedarían amontonados. Además la tracción es una razón, y en escala log x0,5 y x2 quedan a la misma distancia de 1.

P: ¿Por qué no usaron gráficos de torta?

R: Comparar ángulos es menos preciso que comparar longitudes. Para composición usamos barras apiladas al 100%.

P: ¿Qué atributos visuales usaron y por qué?

R: Posición y longitud para los valores (los atributos que el ojo compara con más precisión), color solo para énfasis (preatentivo: gris contexto, azul petróleo oportunidad, rojo alerta; cada color tiene un solo significado), tamaño para volumen en la matriz y forma/línea para tendencias. Evitamos el par verde-rojo, difícil de distinguir con daltonismo, y el color siempre va acompañado de etiquetas.

P: ¿Por qué no usaron verde para lo positivo?

R: Porque verde y rojo juntos son la combinación más difícil de distinguir para personas con daltonismo (cerca del 8% de los hombres). Usamos azul petróleo para oportunidad y rojo para alerta, que difieren en tono y luminosidad, y siempre agregamos etiquetas.

P: ¿Qué principios de Gestalt aplicaron?

R: Proximidad (paneles de películas y series lado a lado), similitud (mismo color para el mismo tipo en todos los productos) y cerramiento (cuadrantes de la matriz y tarjetas en la presentación).

IE11 - Recursos orales, escritos y visuales

P: ¿Cómo integraron los tres recursos?

R: Visual: un gráfico con un énfasis por diapositiva. Escrito: títulos-mensaje y textos breves; el detalle en el informe. Oral: cada integrante explica qué significa el dato y qué decisión implica, sin leer la diapositiva, y se hace una demostración en vivo del dashboard.

IE12 - Conclusiones con evidencia

P: ¿Qué evidencia respalda la recomendación de exponer joyas ocultas?

R: La matriz (documental, música e historia con alta calificación y baja tracción), la curva de concentración (86% de votos en el 10% de series) y la baja correlación popularidad-calificación (0,17-0,23): recomendar por popularidad refuerza la concentración.

P: ¿Cómo sabrían si la recomendación funciona?

R: Con indicadores medidos sobre datos propios de reproducción, porque los votos vienen de la comunidad TMDb y no de nuestros suscriptores: % del catálogo con al menos una reproducción en 90 días y % de reproducciones del top 10%. Hoy solo tenemos el proxy (62% de series con menos de 10 votos; 86% de votos en el top 10%), que sirve como línea base aproximada. El efecto se valida con una prueba A/B.

4. Preguntas técnicas y de datos

P: ¿Por qué usan votos como engagement si no es lo mismo que reproducciones?

R: Porque las fuentes no tienen datos de reproducción. El voto requiere haber visto el título, por lo que es un indicador aproximado razonable. Lo declaramos como limitación y por eso la tercera recomendación es incorporar datos de comportamiento.

P: ¿De dónde vienen los votos?

R: Los archivos son catálogos públicos con metadatos de TMDb: votos, calificación y popularidad reflejan a quienes califican en TMDb, no a los suscriptores de StreamView. Por eso los usamos como indicadores aproximados y la tercera recomendación es medir reproducción real.

P: ¿El índice de tracción usa títulos o asignaciones?

R: Asignaciones título-género: un título con tres géneros aporta a los tres, así las participaciones suman 100%. Por eso decimos que ciencia ficción es el 6,7% de las asignaciones de género de series (el 12,2% de las series tiene ese género). El ranking es el mismo con cualquiera de las dos definiciones.

P: ¿Qué es la calificación ponderada?

R: Un promedio bayesiano: $(v/(v+m)) \times R + (m/(v+m)) \times C$, donde v son los votos del título, R su nota, m la mediana de votos del tipo y C la nota media. Si un título tiene pocos votos, su nota se acerca al promedio; si tiene muchos, se mantiene. Evita que un título con 2 votos y nota 10 aparezca como el mejor.

P: ¿Qué problemas de calidad de datos encontraron?

R: Columna rating duplicada de vote_average; duración vacía o constante; fecha de incorporación idéntica al año de estreno; notas 0 sin votos; presupuestos en 0; 9 duplicados; géneros con nombres distintos entre fuentes; títulos en escrituras no latinas.

P: ¿Por qué no comparan directamente películas con series?

R: Porque las películas concentran el 87% de los votos y las series se califican con otra escala (media 7,1 vs 6,4). Si se mezclan, el comportamiento de las series desaparece. Por eso cada indicador se calcula por tipo.

P: ¿Por qué no analizan el crecimiento del catálogo?

R: La muestra tiene exactamente 1.000 títulos por año y tipo; cualquier conteo por año sería artificial.

P: ¿Por qué Streamlit y no Power BI?

R: Porque permite reutilizar exactamente el mismo código de limpieza y métricas del análisis (una sola fuente de verdad), es gratuito, reproducible con un solo comando y permite interacciones como selección en gráficos y exportación.

P: ¿Qué cambiarían del dashboard?

R: Publicarlo en un servidor con actualización automática, agregar vistas de retención cuando existan datos de uso y validarlo con pruebas de usabilidad con cada gerencia.

5. Demo en vivo (opcional, 60 s)

La pauta no exige una demostración en vivo: basta con presentar el dashboard con la captura de la diapositiva 13. Si hay tiempo y el equipo de la sala funciona, la demo refuerza el indicador IE11 (integración de recursos). Secuencia sugerida:

- Abrir la página 1 y leer el mensaje clave.
- En la barra lateral, filtrar Géneros = Documental: mostrar que la calificación sube y la baja visibilidad aumenta.
- Ir a la página 2, seleccionar la burbuja de Documental y mostrar sus títulos mejor evaluados.

- Ir a la página 5 y activar "Solo joyas ocultas"; mencionar que esa lista puede alimentar una fila de recomendación.
- Restablecer filtros antes de pasar a la siguiente diapositiva.

Si no se hace demo

Explicar las funciones sobre la captura de la diapositiva 13 y tener abierto el informe (sección IX) por si el docente pide ver otra página del dashboard. Si el docente pide ejecutarlo, usar "streamlit run dashboard/app.py" desde la raíz del proyecto.