

Del catálogo al descubrimiento: una solución de visualización para identificar qué contenido genera interacción en StreamView Analytics

Claudio Aro, Guillermo Cerda, Manuel Díaz

Ingeniería en Informática, mención Ciencia de Datos — Escuela de Informática y Telecomunicaciones
Duoc UC, sede Puerto Montt

ADY1104 Visualización de Datos — Evaluaciones Parciales N.º 1 (Encargo) y N.º 2 (Presentación)

Docente: Claudio Andrés Gonzalez Penaloza — Septiembre de 2026

Resumen—StreamView Analytics quiere saber qué contenido genera interacción, cuál gusta a sus usuarios y qué parte de su catálogo no se está descubriendo. Siguiendo CRISP-DM, integramos dos catálogos (16.000 películas y 16.000 series, 2010–2025) en una base de 31.991 títulos y construimos un análisis exploratorio, un dashboard interactivo en Streamlit y una narrativa visual para la gerencia. Tres hallazgos sostienen la idea central, *StreamView no necesita más títulos, sino que los títulos correctos se descubran*: (1) el 10 % de los títulos se lleva el 71 % de los votos en películas y el 86 % en series, y el 62 % de las series tiene menos de 10 votos; (2) ciencia ficción y fantasía genera 2,5 veces más interacción que su peso en las series, mientras talk show, reality y noticias casi no generan; y (3) ser popular no es lo mismo que ser bien evaluado, y hay géneros e idiomas de alta calidad poco vistos. Todas las cifras se verificaron desde los datos originales, y declaramos que los votos son un indicador aproximado del engagement.

Palabras clave—visualización de datos, CRISP-DM, data storytelling, dashboard interactivo, percepción visual, streaming, engagement, descubrimiento de contenido

Tabla I
PREGUNTAS DE NEGOCIO Y ÁREA DE DECISIÓN

N.º	Pregunta	Área de decisión
P1	¿Qué géneros generan más (o menos) interacción que su peso en la oferta?	Adquisiciones
P2	¿Qué géneros están bien evaluados pero son poco descubiertos?	Producto / UX
P3	¿Qué tan concentrada está la interacción?	Producto / UX
P4	¿Cuánto del catálogo es invisible?	Estrategia internacional
P5	¿Qué idiomas ofrecen mejor calidad percibida?	Estrategia internacional
P6	¿Cómo evoluciona la calidad percibida en el tiempo?	Contenidos
P7	¿La popularidad refleja la satisfacción?	Recomendación
P8	¿Qué géneros de película son más rentables? ¿Cómo impactó la pandemia?	Finanzas
P9	¿De qué países proviene el contenido?	Estrategia internacional

I. DESCRIPCIÓN DEL PROBLEMA DE NEGOCIO

CRISP-DM · Fase 1: comprensión del negocio

I-A. Contexto organizacional

StreamView Analytics es una plataforma internacional de streaming que vive de suscripciones. Su rentabilidad depende de dos palancas: que el usuario encuentre contenido de su interés (*engagement*) y que siga suscrito (*retención*). En este negocio, un catálogo grande no garantiza valor: si el usuario no descubre los títulos adecuados, percibe que “no hay nada que ver”.

I-B. Problema

La organización tiene información de su catálogo, pero no una vista consolidada que responda qué contenido genera interacción, cuál satisface, qué parte del catálogo no se descubre y dónde conviene invertir. Hoy esas decisiones se toman con reportes aislados por tipo de contenido y sin indicadores comparables entre películas y series.

I-C. Preguntas de negocio

La Tabla I traduce el problema en ocho preguntas. Cada pregunta tiene una visualización que la responde (Sección VI) y un área que toma la decisión.

II. OBJETIVOS DEL PROYECTO

Objetivo general. Diseñar e implementar una solución de visualización que integre las fuentes del catálogo de StreamView y comunique, de forma clara y adaptada a cada audiencia, qué contenido genera interacción, cuál satisface y cuál no está siendo descubierto, para apoyar decisiones de retención, engagement y experiencia de usuario.

Objetivos específicos.

1. Integrar y depurar las fuentes de películas y series en un catálogo único con indicadores comparables.
2. Responder P1–P8 con un análisis exploratorio visual que identifique patrones, tendencias y relaciones.
3. Diseñar visualizaciones que apliquen principios de percepción visual y atributos preatentivos para reducir la carga cognitiva.
4. Construir un dashboard interactivo con KPIs, filtros, navegación y exploración a nivel de título.
5. Desarrollar una narrativa visual para la gerencia, con recomendaciones basadas en evidencia.
6. Evaluar críticamente la solución y verificar que cada afirmación sea reproducible desde los datos.




Figura 1. Ciclo CRISP-DM aplicado al proyecto. Las flechas dobles y la línea punteada representan las iteraciones descritas en la Secc. III.

III. METODOLOGÍA: CRISP-DM

Seguimos CRISP-DM [5], un proceso de seis fases que parte del problema de negocio y termina con la entrega de la solución. Lo elegimos porque empieza por el negocio y la audiencia, separa la preparación de los datos de su análisis y permite volver atrás cuando algo no cuadra. La Fig. 1 muestra el ciclo y la Tabla II, qué hicimos en cada fase. Como el objetivo es explicar y no predecir, en la fase de *modelado* construimos indicadores y gráficos, no un modelo predictivo.

Iteraciones. El proceso no fue lineal: las notas 0 sin votos nos hicieron volver a la preparación; los promedios engañosos por género, al modelado (calificación ponderada); y descubrir que los votos vienen de TMDb nos llevó de vuelta al negocio para redefinir las metas con datos propios de reproducción.

IV. AUDIENCIA OBJETIVO Y PROPÓSITO COMUNICACIONAL

CRISP-DM · Fase 1: comprensión del negocio

IV-A. Audiencias

La solución tiene cuatro audiencias con necesidades distintas (Tabla III). Por eso se diseñaron dos productos complementarios: una **narrativa lineal** (este informe y la presentación ejecutiva) para quien decide y un **dashboard exploratorio** para quien opera.

IV-B. Propósito comunicacional

El propósito principal es **persuadir para la acción**: que la gerencia apruebe tres líneas de trabajo (mejorar el descubrimiento, reorientar la adquisición y medir el comportamiento real del usuario). El propósito secundario es **informar y habilitar la exploración**: que las gerencias de contenido y producto respondan sus propias preguntas sin depender del equipo de analítica. El propósito se deriva del problema: si el catálogo no se descubre, el usuario percibe menos valor y la retención se debilita. Cada visualización demuestra un eslabón de esa cadena (concentración, desalineación entre oferta e interacción, calidad no vista) y termina en una decisión.

IV-C. Estrategia de comunicación y su justificación

La estrategia se deriva de dos hechos: la audiencia primaria decide con poco tiempo y sin perfil técnico, y el propósito es que apruebe decisiones concretas. Por eso cada recurso se eligió por su efecto en esa audiencia y se descartó la alternativa que habría dificultado la decisión (Tabla IV). La estrategia se adapta en cada producto: la presentación usa el arco completo y una idea por diapositiva; el informe mantiene la pirámide invertida (resumen y recomendaciones primero) y agrega la evidencia técnica; y el dashboard parte de un resumen ejecutivo y baja al detalle según la necesidad de cada gerencia.

V. FUENTES DE DATOS E INTEGRACIÓN

CRISP-DM · Fases 2 y 3: comprensión y preparación de los datos

V-A. Fuentes utilizadas

El caso considera fuentes de usuarios, reproducciones, suscripciones y dispositivos, pero los archivos entregados describen el *catálogo* (Tabla V). Sus identificadores y variables (*popularity*, *vote_count*, *vote_average*) corresponden a datos públicos de The Movie Database (TMDb) [1]. Es decir, los votos y la calificación vienen de la comunidad de TMDb, no de los suscriptores de StreamView, así que los usamos como **indicadores aproximados** de interacción y satisfacción. Además, cada fuente trae exactamente 1.000 títulos por año y tipo: es una selección, no el catálogo completo, por lo que no sacamos conclusiones sobre su crecimiento.

V-B. Variables relevantes

La Tabla VI resume las variables que alimentan las visualizaciones y su rol analítico.

V-C. Calidad de datos y decisiones de limpieza

La Tabla VII documenta cada problema detectado, su evidencia y la decisión tomada.

V-D. Integración y arquitectura

La integración (*src/preparacion.py*) produce tres tablas cuya llave es el par (*id*, *tipo*): (1) *catalogo_integrado.csv*, una fila por título con 23 variables; (2) *catalogo_generos.csv*, formato largo con 65.788 asignaciones título-género; y (3) *catalogo_paises.csv*, con 37.628 relaciones título-país. Un único módulo de métricas alimenta los notebooks, las figuras, el dashboard y este informe (Fig. 2), por lo que las cifras son idénticas en todos los productos.

V-E. Indicadores construidos

- **Calificación ponderada**: un promedio que acerca a la media las notas de los títulos con pocos votos. Así, un título con 2 votos y nota 10 no supera a uno con 20.000 votos y nota 8,5.
- **Índice de tracción**: cuánto pesa un género en los votos comparado con cuánto pesa en la oferta. Si vale 1, rinde lo que pesa; 2,5 significa que genera 2,5 veces más

Tabla II
APLICACIÓN DE CRISP-DM: ACTIVIDADES, RESULTADOS Y SECCIÓN DONDE SE DOCUMENTA CADA FASE

Fase	Actividades en este proyecto	Resultado / entregable	Sección
1. Comprensión del negocio	Contexto de StreamView, problema, 8 preguntas de negocio, audiencias, propósito comunicacional y estrategia	Preguntas P1–P8, mapa de audiencias, idea central	I, II, IV
2. Comprensión de los datos	Descripción de las 2 fuentes (32.000 registros), tipos de variables, diagnóstico de calidad, identificación del origen TMDb y de la muestra por cuota	Tablas V–VII; notebook 01	V-A a V-C
3. Preparación de los datos	Eliminación de redundancias y duplicados, nulos semánticos, unificación en 21 géneros, normalización de textos, tablas largas título-género y título-país	3 tablas en <code>data/processed</code> (31.991 títulos); <code>src/preparacion.py</code>	V-D
4. Modelado (analítico-descriptivo y visual)	Indicadores (calificación ponderada, índice de tracción, concentración y cuadrantes), análisis exploratorio P1–P8 y elección de los gráficos	<code>src/metricas.py</code> , 9 figuras, notebook 02	V-E, VI, VII
5. Evaluación	Reproducción completa, verificación automática de 76 cifras, pruebas de robustez, evaluación crítica frente a los objetivos de negocio	<code>src/verificacion.py</code> , Tabla IX, fortalezas y limitaciones	V-F, X
6. Despliegue	Narrativa visual, dashboard interactivo, presentación ejecutiva, recomendaciones con indicadores de seguimiento y proyecto reproducible	Dashboard Streamlit, este informe, presentación, README	VIII, IX, XI

Tabla III
AUDIENCIAS, NECESIDAD DE INFORMACIÓN Y PRODUCTO ASIGNADO

Audiencia	Necesidad	Nivel de detalle	Producto
Directorio y gerencia general (primaria)	Qué pasa, por qué importa y qué decidir; poco tiempo, sin perfil técnico	Bajo: 1 idea central, 3 hallazgos, 3 decisiones	Presentación, resumen, Secc. XI
Contenidos y adquisiciones	Qué géneros, idiomas y orígenes priorizar	Medio: comparación por género e idioma	Dashboard págs. 2–3
Producto y UX	Qué parte del catálogo no se descubre y cómo exponerla	Medio: visibilidad, concentración, joyas ocultas	Dashboard págs. 1, 2 y 5
Equipo de analítica (secundaria)	Reproducir, auditar supuestos y extender	Alto: datos, código, definiciones	Notebooks, <code>src/</code> , pág. 6




Figura 2. Arquitectura de la solución: una sola fuente de verdad para todos los productos.

interacción que su peso. Se calcula sobre las asignaciones título-género (un título con tres géneros cuenta para los tres).

- **Baja visibilidad:** títulos con menos de 10 votos.
- **Concentración:** qué parte de los votos se lleva el 10 % de títulos más votados.
- **Bien evaluados:** títulos con nota 7 o más.
- **ROI:** ganancia de taquilla sobre el presupuesto (solo

películas; no mide ingresos de la plataforma).

V-F. Verificación y reproducibilidad

Regeneramos todo el proyecto desde los CSV originales y obtuvimos exactamente los mismos resultados. Los notebooks y las seis páginas del dashboard funcionan sin errores, y un script (`src/verificacion.py`) recalcula automáticamente cada cifra de este informe. Cuando un resultado depende de un supuesto, lo decimos y mostramos qué pasa si el supuesto cambia.

VI. ANÁLISIS EXPLORATORIO MEDIANTE VISUALIZACIONES

CRISP-DM · Fases 2 y 4: comprensión de los datos y modelado descriptivo

La Tabla VIII sitúa el catálogo. Las series tienen mejor calificación que las películas, pero reciben 6,7 veces menos votos y su mediana es de solo 4 votos por título. Como las escalas difieren, películas y series se analizan siempre por separado.

VI-A. P3: la interacción se concentra en muy pocos títulos

Hallazgo. El 10 % de los títulos más votados concentra el 71 % de los votos en películas y el 86 % en series (Fig. 3). En series, el 22,9 % no tiene ningún voto y otro 38,6 % tiene entre 1 y 9; el 61,6 % es prácticamente invisible. En películas esa proporción es 11,4 % (Fig. 4).

Implicancia. La plataforma depende de pocos éxitos, y el resto del catálogo casi no aporta a la retención. Un recomendador basado solo en popularidad refuerza este patrón.

VI-B. P1: la interacción está desalineada con la oferta

Hallazgo. En series, ciencia ficción y fantasía reúne el 6,7 % de las asignaciones de género y el 16,5 % de los votos (tracción 2,5). Le siguen acción y aventura (1,98), misterio (1,75) y crimen (1,68). Contado por títulos, el 12,2 % de las series tiene ese género y concentra el 41 % de sus votos. En el otro extremo están talk show (0,06), reality (0,09), noticias

Tabla IV
ESTRATEGIA DE COMUNICACIÓN: DECISIÓN, JUSTIFICACIÓN SEGÚN AUDIENCIA Y OBJETIVO, Y ALTERNATIVA DESCARTADA

Decisión	Justificación (audiencia y objetivo)	Alternativa descartada y por qué
Pirámide invertida	La gerencia decide con poco tiempo: debe obtener la conclusión y la decisión en el primer minuto; el detalle queda disponible para quien lo pida	Relato cronológico del análisis: entierra la conclusión al final
Una idea central	“No necesitamos más títulos: necesitamos que se descubran los correctos” es memorable, ordena todos los gráficos y guía la discusión hacia la decisión	Lista de hallazgos independientes: dispersa la atención y no persuade
Arco en tres actos	Contexto, conflicto y resolución crean tensión (el problema) y la resuelven con acciones, lo que facilita recordar el mensaje y aprobar las decisiones	Estructura por fuente de datos: organiza por cómo trabajamos, no por lo que la audiencia necesita
Títulos-mensaje [2]	El título dice el hallazgo y el gráfico lo demuestra: se reduce la interpretación y la carga cognitiva de una audiencia no técnica	Títulos descriptivos (“Votos por género”): obligan a deducir la conclusión
Dos productos	Narrativa lineal para quien decide y dashboard para quien opera: las audiencias difieren en tiempo, perfil y necesidad de detalle (Tabla III)	Un único dashboard para todos: sobrecarga a la gerencia y no sostiene un argumento
Lenguaje de negocio	“Índice de tracción”, “joyas ocultas” y “baja visibilidad” se entienden sin formación estadística	Jerga estadística en el mensaje principal: aleja a la audiencia primaria
Recomendaciones con responsable e indicador	Convierte el hallazgo en una decisión asignable y verificable; declara el proxy actual para no prometer lo que los datos no miden	Recomendaciones genéricas sin dueño ni meta: no se pueden aprobar ni seguir
Evidencia visible y limitaciones declaradas	Cada afirmación cita su figura y las limitaciones se dicen de frente: aumenta la credibilidad ante una gerencia que decidirá inversión	Ocultar limitaciones: arriesga la confianza si el docente o la gerencia las detecta

Tabla V
FUENTES DE DATOS

Fuente	Registros	Contenido
netflix_movies_detailed_up_to_2025.csv	16.000 × 18	Título, director, reparto, país, idioma, géneros, año, popularidad, votos, calificación, presupuesto y recaudación
netflix_tv_shows_detailed_up_to_2025.csv	16.000 × 16	Mismas variables descriptivas, sin presupuesto ni recaudación




Figura 3. **La interacción se concentra en muy pocos títulos.** Curva de Lorenz de los votos por título; la distancia a la diagonal mide la desigualdad.

(0,10) y documental (0,21): el 14 % de las series lleva alguno de los tres primeros y recibe solo el 1,6 % de los votos. En películas lideran ciencia ficción y fantasía (1,85) y acción y aventura (1,63); documental (0,17) y películas para TV (0,20)

Tabla VI
VARIABLES RELEVANTES PARA EL ANÁLISIS

Variable integrada	Tipo de dato	Uso analítico
tipo	Categoría nominal	Segmentar película / serie
anio	Ordinal temporal	Tendencias 2010–2025
generos	Categoría multivalor	Oferta, tracción y calidad por género
idioma	Categoría nominal	Calidad por idioma original
países	Categoría multivalor, geográfica	Origen del contenido (mapa, ranking)
votos, visibilidad	Cuantitativa discreta / ordinal	Proxy de interacción; tramos de visibilidad
calificacion	Cuantitativa (0–10)	Proxy de satisfacción
calif_ponderada	Cuantitativa derivada	Satisfacción corregida por n.º de votos
popularidad	Cuantitativa continua	Atención reciente (índice TMDB)
presupuesto, recaudacion, roi	Cuantitativa continua	Rentabilidad en taquilla (películas)
titulo, director, reparto	Texto	Búsqueda en el explorador

quedan al final. Drama, el género con más títulos, rinde bajo su peso en películas (0,78) (Fig. 5).

Implicancia. Hay espacio para reasignar presupuesto de adquisición hacia géneros con alta tracción. Advertencia: reality y talk show pueden consumirse sin que el público los califique en TMDB; su baja tracción debe confirmarse con datos propios de reproducción antes de desinvertir.

Tabla VII
DIAGNÓSTICO DE CALIDAD DE DATOS Y DECISIONES DE LIMPIEZA (VERIFICADAS EN NOTEBOOKS/01_INTEGRACION_LIMPIEZA.IPYNB)

Problema	Evidencia	Decisión
Columna redundante	rating = vote_average en el 100 % de las filas	Se elimina rating
Duración no informativa	Vacía en películas; valor único “1 Seasons” en series	Se excluye
Fecha de incorporación	Su año coincide en el 100 % con el año de estreno	Se usa solo el año de estreno
Nota 0 sin votos	894 películas y 3.666 series con 0 votos	Calificación nula (“sin evaluar”), no nota 0
Montos en 0	Solo el 30,3 % de las películas informa presupuesto	Se dejan vacíos; el ROI se calcula solo con montos de al menos USD 100.000 (3.362 películas, 21 %)
Duplicados	9 id repetidos en series, filas idénticas	Se eliminan: 31.991 títulos (16.000 películas y 15.991 series)
Taxonomías distintas	19 géneros en películas y 17 en series, con nombres distintos (“Sci-Fi & Fantasy” vs. “Science Fiction” y “Fantasy”)	Se unifican en 21 géneros en español más “Sin clasificar” (16 presentes en cada tipo)
Escrituras no latinas	704 títulos (686 series) en coreano, chino, etc.	Se normalizan; si no es posible, se rotulan con su id
Muestra por cuota	1.000 títulos por año y tipo	No se analiza crecimiento del volumen

Tabla VIII
KPIs DEL CATÁLOGO INTEGRADO

Indicador	Películas	Series	Catálogo
Títulos	16.000	15.991	31.991
Votos totales	11.498.498	1.712.228	13.210.726
Mediana de votos por título	138	4	43
Calificación ponderada media	6,38	7,12	6,71
% con nota 7 o más	25,8 %	61,8 %	42,0 %
% con menos de 10 votos	11,4 %	61,6 %	36,4 %
% de votos del top 10 %	71,0 %	85,9 %	79,2 %
ROI mediano (taquilla)	80,7 %	n/a	—
Idiomas originales	74	71	83




Figura 4. Seis de cada diez series son prácticamente invisibles. Distribución de títulos por tramo de votos recibidos.

VI-C. P2: hay contenido bien evaluado que no se descubre

Hallazgo. Con las medianas como umbral, los *motores* (alta calidad, alta tracción) en series son ciencia ficción y fantasía, acción y aventura, animación, crimen, misterio, historia y bélico, y drama (este último justo en el umbral). En películas lo son animación, familiar y ciencia ficción y fantasía. Las *joyas ocultas* (alta calidad, baja tracción) más marcadas son documental, música e historia y bélico en películas: el 54 % de los documentales tiene nota 7 o más, frente al 26 % del total de películas. En series, la joya oculta es documental. Drama y romance (películas) también caen en ese cuadrante, pero

cerca del umbral de calidad. Terror tiene la calificación más baja y además baja tracción (0,74); suspenso tiene tracción proporcional (1,00) y calidad bajo la mediana (Fig. 6).

Implicancia. Las joyas ocultas son contenido ya disponible, valorado por quien lo ve y poco expuesto: es el insumo más barato para mejorar la experiencia mediante recomendación.

VI-D. P6: popularidad y calidad son dimensiones distintas

Hallazgo. La relación entre popularidad y calificación es débil: la correlación es de solo 0,23 en películas y 0,17 en series (Fig. 7). Muchos títulos populares tienen notas medias y muchos títulos muy bien evaluados son poco populares.

Implicancia. Si la recomendación privilegia la popularidad, refuerza la concentración y oculta calidad. Conviene combinar popularidad con calificación ponderada.

VI-E. P4: idioma original y calidad percibida

Hallazgo. Entre los idiomas con 200 o más títulos evaluados, el japonés tiene la mayor proporción de títulos bien evaluados: 52 % en películas y 72 % en series. En películas, coreano (39 %) y español (35 %) superan ampliamente al inglés (21 %), que reúne el 60 % de las películas evaluadas y el 88 % de sus votos (Fig. 8). En series, el coreano (57 %) queda *bajo* el inglés (60 %). La Tabla IX muestra que el liderazgo japonés en películas se mantiene con cualquier umbral de votos, mientras que en series su posición depende del umbral (cuarto con 1 o 10 votos mínimos, segundo con 50). Además, el 56 % de las películas y el 77 % de las series japonesas son animación: el efecto es principalmente anime.

Implicancia. El anime japonés es una apuesta de diferenciación robusta en ambos tipos. La producción coreana está respaldada en películas; en series, la evidencia es mixta.

VI-F. P5: evolución de la calidad percibida

Hallazgo. Entre 2010 y 2024, la proporción de títulos bien evaluados pasa de 20 % a 28 % en películas y de 56 % a 71 % en series. La tendencia es al alza, pero con retrocesos: las películas alcanzan su máximo en 2019 (31 %) y retroceden, y las series caen en 2016 y en 2021–2022 (Fig. 9). La mediana de votos de las películas baja de 221 (2019) a 61 (2024). Los




Figura 5. Ciencia ficción y acción generan hasta 2,5 veces más interacción que su peso en la oferta; talk show, reality y noticias casi no generan interacción. Participación de cada género en la oferta (círculo blanco, % de asignaciones título-género) y en la interacción (círculo relleno, % de votos). La etiqueta es el índice de tracción. Petróleo: 1,5 o más; rojo: 0,4 o menos; gris: contexto.




Figura 6. Documental, música e historia: bien evaluados, pero poco descubiertos. Matriz calidad vs. interacción por género; tamaño = n.º de títulos; líneas punteadas = medianas de los géneros.

títulos recientes tienen menos evaluaciones, así que parte del alza puede ser un sesgo de antigüedad. 2025 no se interpreta. **Implicancia.** La calidad percibida no es el problema del catálogo. El foco debe estar en el descubrimiento.

VI-G. P7: rentabilidad de las películas

Hallazgo. Terror (150 %), animación (137 %) y familiar (119 %) tienen el mayor ROI mediano; drama (39 %) e historia

y bélico (17 %), el menor. Terror combina baja calificación con alta rentabilidad por sus presupuestos acotados. El ROI mediano anual promedió cerca de 104 % entre 2011 y 2019, cayó a -17 % en 2020 y llegó a 61 % en 2024. El dato de 2025 se basa en solo 24 películas con recaudación incompleta (Fig. 10).

Implicancia. Es relevante solo para coproducciones o licencias con ventana de cine: el ROI mide taquilla, no el valor del título




Figura 7. **Ser popular no es lo mismo que ser bien evaluado.** Popularidad vs. calificación en títulos con 10 o más votos (hexbin; tono más oscuro = más títulos).

Tabla IX

¿CAMBIA EL RESULTADO SI EXIGIMOS MÁS VOTOS? TRES IDIOMAS CON MAYOR % DE TÍTULOS CON NOTA 7 O MÁS (IDIOMAS CON 100 O MÁS TÍTULOS)

Votos mín.	Películas	Series
1	Japonés 52 %, portugués 41 %, coreano 39 %	Cantonés 82 %, tailandés 78 %, ruso 73 % (japonés 72 %, 4.º)
10	Japonés 54 %, coreano 48 %, portugués 38 %	Español 84 %, turco 80 %, chino 79 % (japonés 77 %, 4.º)
50	Japonés 59 %, coreano 58 %, español 37 %	Coreano 97 %, japonés 94 %, español 93 %

dentro de la plataforma.

VI-H. P8: origen del contenido

Hallazgo. Estados Unidos participa en 10.955 títulos: el 48,5 % de las películas y el 20,0 % de las series. Japón (11,8 % de las series vs. 6,2 % de las películas), China (11,9 % vs. 3,1 %) y Corea del Sur (8,1 % vs. 5,5 %) pesan mucho más en series (Fig. 11), lo que coincide con la buena evaluación del contenido japonés.

VII. DISEÑO Y JUSTIFICACIÓN DE LAS REPRESENTACIONES GRÁFICAS

CRISP-DM · Fase 4: modelado visual

VII-A. Principios de percepción visual y jerarquía

- **Atención preatentiva:** el color se reserva para el mensaje. El contexto va en gris y solo el dato relevante recibe acento, de modo que el ojo lo detecta antes de leer.
- **Gestalt:** *proximidad* (paneles de películas y series lado a lado con ejes comparables), *similitud* (el mismo color significa lo mismo en informe, presentación y dashboard), *cerramiento* (cuadrantes rotulados en la matriz) y *continuidad* (líneas para el tiempo).
- **Jerarquía visual:** título-mensaje (en la leyenda del paper y dentro del gráfico en dashboard y presentación),

Tabla X
USO DE ATRIBUTOS VISUALES

Atributo	Uso	Justificación
Posición	Valores en ejes comunes (Fig. 3, 5, 6, 9)	Atributo más preciso para comparar cantidades
Longitud	Barras ordenadas (Fig. 4, 8, 10, 11)	Comparación rápida con base común
Color (tono)	Azul pizarra = películas, ámbar = series, petróleo = oportunidad, rojo = alerta, gris = contexto	Un solo significado por tono; evita el par verde-rojo, difícil de distinguir con daltonismo
Color (luminosidad)	Escala de rojo a azul en visibilidad; gris en hexbin	Orden: más oscuro = más títulos o más votos
Tamaño	N.º de títulos por género en la matriz	Tercera variable sin agregar un eje; uso secundario
Contraste	Negrita en títulos y en el valor destacado; texto de apoyo en gris	Guía la lectura y separa mensaje de contexto
Forma	Círculo vacío (oferta) vs. lleno (interacción); línea para el tiempo	Distingue dos medidas en el mismo eje

subtítulo con lo que se mide y fuente al pie. El lector recorre la figura en el orden en que debe entenderla.

- **Relación dato-tinta:** sin bordes superiores ni derechos, cuadrícula mínima y etiquetas directas en vez de leyendas [3].

VII-B. Atributos visuales

Los atributos se asignan según su precisión perceptiva: posición y longitud para los valores que se comparan, y color y tamaño para atributos secundarios [4]. La Tabla X detalla el uso de cada uno.

VII-C. Reducción de la carga cognitiva

Para no saturar al lector limitamos cada figura a un mensaje y cada dashboard a seis KPIs. Además, rotulamos directamente en lugar de usar leyendas, ordenamos las barras por valor, usamos escala logarítmica cuando el rango lo exige (tracción de 0,06 a 2,5; popularidad) y aplicamos formato numérico local (coma decimal). También anotamos en el gráfico las advertencias necesarias (2025 con pocos votos, pocos datos), para que el lector no tenga que buscarlas en el texto.

VII-D. Selección de gráficos según la naturaleza de los datos

La Tabla XI relaciona cada figura con la estructura de sus datos y la tarea analítica, y registra la alternativa descartada.

VIII. DESARROLLO DE LA NARRATIVA VISUAL (DATA STORYTELLING)

CRISP-DM · Fase 6: despliegue (comunicación)

VIII-A. Estructura

La narrativa está dirigida a la audiencia primaria y se presenta en diez minutos. Sigue un arco de tres actos (contexto, conflicto y resolución) que va de la situación a la decisión [2] (Fig. 12 y Tabla XII).




Figura 8. **El contenido japonés es el mejor evaluado; el inglés domina en volumen, no en calidad.** % de títulos con nota 7 o más por idioma original (idiomas con 200 o más títulos evaluados). Petróleo = máximo; azul/ámbar = inglés como referencia.

Tabla XI
SELECCIÓN DEL TIPO DE GRÁFICO SEGÚN LA NATURALEZA DE LOS DATOS Y LA TAREA

Fig.	Tipo de gráfico	Naturaleza de los datos	Tarea	Por qué este gráfico	Alternativa descartada
3	Curva de Lorenz	Distribución de una variable cuantitativa (votos) en 16.000 títulos	Concentración	Estándar para desigualdad; la distancia a la diagonal es la brecha	Pareto de barras: 16.000 barras ilegibles
4	Barra apilada 100 %	5 tramos ordenados, 2 categorías	Composición	Tramos ordenados con color secuencial	Torta: los ángulos se comparan peor
5	Mancuernas (dumbbell)	2 proporciones por categoría nominal	Brecha entre dos medidas	La longitud de la línea es la brecha	Barras agrupadas: duplican elementos
6	Burbujas por cuadrantes	2 cuantitativas + 1 de tamaño, por categoría	Relación y segmentación	Los cuadrantes traducen el dato a una acción	Tabla: exige comparar mentalmente
7	Hexbin	2 cuantitativas, más de 20.000 puntos	Correlación	Evita la sobreposición de puntos	Dispersión simple: saturada
8	Barras horizontales ordenadas	1 proporción por categoría nominal con nombres largos	Ranking	Lectura fácil y orden explícito	Mapa: el idioma no es geográfico
9	Línea temporal	Proporción por año (ordinal temporal)	Tendencia	La continuidad se percibe como evolución	Barras por año: fragmentan la tendencia
10	Barras + línea	Mediana por categoría y por año	Ranking y tendencia	Cada panel usa el gráfico de su tarea	Boxplot: menos accesible para la gerencia
11	Barras apiladas horizontales	Conteo por país y tipo	Ranking con composición	Total y mezcla en una barra	Mapa coroplético (se usa en el dashboard)




Figura 9. **La proporción de títulos bien evaluados tiende a subir desde 2010, con retrocesos.** % de títulos con nota 7 o más por año de estreno. 2025 se sombrea por tener pocos votos.

VIII-B. Integración de recursos orales, escritos y visuales

Visual: una idea por diapositiva y un gráfico con un solo énfasis de color. Las figuras de la presentación se rediseñan con un panel y texto de al menos 11 pt para la proyección. **Es-crito:** títulos-mensaje y un máximo de dos líneas de apoyo; el detalle queda en este informe y en las notas del orador. **Oral:** cada integrante narra un acto y explica “qué significa” y “qué hacemos con esto”, sin leer la diapositiva. **Demostración:** en el acto 3, filtrar el dashboard por *Documental* muestra en vivo una joya oculta: la calificación sube (66 % bien evaluados vs. 42 % del catálogo) y la baja visibilidad también (47 % vs. 36 %).

VIII-C. Plan de exposición

La presentación dura diez minutos y cada integrante narra un bloque del arco (Tabla XIII). Como la nota es individual y puede haber preguntas cruzadas, los tres integrantes preparan todo el contenido con la guía de defensa.




Figura 10. Terror y animación son los géneros más rentables en taquilla; el ROI aún no vuelve a niveles previos a 2020. ROI mediano de películas con presupuesto y recaudación informados (3.362 películas).




Figura 11. Estados Unidos domina el origen; Asia pesa más en series que en películas. Diez países con más títulos (coproducciones cuentan para cada país).



Figura 12. Arco narrativo: la tensión crece con la evidencia del problema y se resuelve con decisiones medibles.

VIII-D. Coherencia entre visualizaciones, audiencia y propósito

La Tabla XIV verifica que cada pieza visual responde una pregunta de negocio, llega a la audiencia correcta y sostiene una decisión. Así se evitan gráficos “decorativos” sin propósito.

Tabla XII
GUION DE LA NARRATIVA Y RECURSOS DE COMUNICACIÓN

Acto	Mensaje	Evidencia	Recurso
1. Contexto	Catálogo amplio (31.991 títulos, 83 idiomas) cuya calidad percibida no es el problema	Tabla VIII, Fig. 9	Oral: situar
2. Conflicto	La interacción se concentra en el 10 % de los títulos y el 62 % de las series es invisible	Fig. 3, 4	Visual: cifra en grande
2. Conflicto	Se ofrece mucho de lo que no genera interacción y se esconde lo que el usuario valora	Fig. 5, 6, 8	Visual: énfasis de color
3. Resolución	“No necesitamos más títulos: necesitamos que se descubran los correctos”	Idea central	Escrito: frase única
3. Resolución	Tres decisiones con indicadores y un plan para medir comportamiento real	Tabla XVI, dashboard	Oral + visual: llamado a la acción

Tabla XIII
PLAN DE EXPOSICIÓN Y RECURSOS POR BLOQUE

Integrante	Diap.	Tiempo	Contenido y recurso dominante
Claudio Aro	1–5	3:00	Acto 1: problema, audiencias, estrategia, CRISP-DM y datos. Oral para situar; tarjetas visuales
Guillermo Cerda	6–11	3:40	Acto 2: hallazgos y justificación técnica de los gráficos. Visual: cifra grande y un énfasis de color
Manuel Díaz	12–16	3:00	Acto 3: idea central, dashboard, recomendaciones, evaluación y cierre. Escrito (frase única) y llamado a la acción

IX. DISEÑO E IMPLEMENTACIÓN DEL DASHBOARD INTERACTIVO

CRISP-DM · Fase 6: despliegue (herramienta)

Tabla XIV
MATRIZ DE COHERENCIA: VISUALIZACIÓN, PREGUNTA, AUDIENCIA, PROPÓSITO Y DECISIÓN

Visualización	Preg.	Audiencia principal	Propósito	Decisión que habilita
Lorenz y visibilidad (Fig. 3, 4)	P3	Gerencia general; Producto/UX	Persuadir (conflicto)	Priorizar el descubrimiento sobre la compra de más títulos
Tracción (Fig. 5)	P1	Gerencia general; Contenidos	Persuadir (conflicto)	Reasignar presupuesto de adquisición por género
Matriz (Fig. 6)	P2	Producto/UX; Contenidos	Persuadir e informar	Crear filas de “joyas ocultas”
Popularidad vs. calificación (Fig. 7)	P6	Producto/UX; Analítica	Informar	Combinar popularidad con calidad en el ranking
Idiomas y países (Fig. 8, 11)	P4, P8	Contenidos; estrategia internacional	Informar	Ampliar anime y contenido japonés
Tendencia (Fig. 9)	P5	Gerencia general	Contextualizar	Descartar la calidad como problema principal
ROI (Fig. 10)	P7	Finanzas / producción	Informar	Géneros para coproducción con ventana de cine
Dashboard (Fig. 13–14)	P1–P8	Gerencias operativas; Analítica	Habilitar la exploración	Consultas propias sin depender de analítica

Tabla XV
COMPONENTES DEL DASHBOARD

Componente	Implementación
KPIs (6)	Títulos, votos, calificación ponderada, % bien evaluados, % baja visibilidad y concentración top 10 %. Al filtrar, muestran la diferencia contra el catálogo completo (con color invertido cuando subir es malo).
Filtros globales (5)	Tipo, rango de años, géneros, idioma original y votos mínimos; botón para restablecer; aplican a todas las páginas.
Navegación (6 páginas)	Resumen ejecutivo; géneros; idiomas y origen; tendencias; explorador de títulos; metodología y glosario.
Interacción	Tooltips; selección por clic o lazo en la matriz que despliega los títulos del género; selector de indicador en tendencias; mapa con zoom; búsqueda por título, director o reparto; interruptor “solo joyas ocultas”.
Exportación	Descarga en CSV de la selección filtrada.
Ayuda y estados	Íconos de ayuda en cada KPI, recuadro “cómo leer” por página, mensajes calculados sobre la selección y aviso cuando un filtro deja la vista sin datos.

IX-A. Tecnología y componentes

El dashboard se implementó con Streamlit (interfaz y navegación) y Plotly (gráficos interactivos), reutilizando los módulos `src/` del análisis. Se ejecuta con `streamlit run dashboard/app.py`. La Tabla XV resume sus componentes.

IX-B. Decisiones de diseño

- **Lectura en Z y de lo general a lo particular:** KPIs arriba, mensaje clave, gráficos de síntesis y, al final, tablas de detalle [6].
- **Un solo lugar de control:** los filtros de la barra lateral aplican a todas las páginas y mantienen la coherencia entre vistas.
- **Consistencia cromática** con el informe y la presentación: el usuario aprende los colores una sola vez.
- **Seis KPIs como máximo**, para no superar la capacidad de la memoria de trabajo.
- **Textos dinámicos:** los mensajes de la página de tendencias se calculan sobre la selección y no se escriben

como cifras fijas, de modo que el texto nunca contradice al gráfico.

X. EVALUACIÓN CRÍTICA DE LA SOLUCIÓN

CRISP-DM · Fase 5: evaluación

X-A. Fortalezas

- **Una sola fuente de verdad:** datos y métricas centralizados en `src/`; las cifras del dashboard, las figuras, la presentación y este informe son idénticas y reproducibles con tres comandos.
- **Indicadores comparables** entre películas y series: taxonomía unificada, calificación ponderada e índice de tracción.
- **Afirmaciones verificadas:** cada hallazgo se recalculó y los que dependen de un supuesto se presentan con su prueba de robustez (Tabla IX).
- **Narrativa con una idea central** y un dashboard con exploración real (selección en gráficos, búsqueda, exportación).

X-B. Limitaciones

- **Proxies externos:** votos, calificación y popularidad provienen de TMDb, no de los suscriptores de StreamView. Miden a quien califica, que no representa a toda la base, y no permiten medir retención ni abandono.
- **Sin datos de comportamiento:** no hay reproducciones, minutos vistos, suscripciones ni dispositivos, fuentes que el caso sí menciona.
- **Muestra por cuota:** 1.000 títulos por año y tipo, con un criterio de selección no documentado; no permite analizar crecimiento ni generalizar al catálogo completo.
- **Sesgo de antigüedad:** los títulos recientes acumulan menos votos; afecta la tendencia (Fig. 9) y el ROI de 2025.
- **Series con pocos votos:** en series, la calificación ponderada corrige poco porque la referencia es de solo 9 votos; las joyas ocultas de series tienen una mediana de 4 votos, así que son candidatas, no evidencia firme.






Figura 13. Dashboard. Izquierda: página 1 (resumen ejecutivo) con filtros globales, seis KPIs, mensaje clave y tracción por género. Derecha: página 2, matriz interactiva calidad vs. interacción; seleccionar burbujas despliega los títulos mejor evaluados del género.

Géneros: oferta vs interacción



Tendencias 2010-2025



Explorador de títulos




Figura 14. Dashboard. Izquierda: página 4 (tendencias), con selector de indicador y lectura calculada sobre la selección. Derecha: página 5 (explorador), con búsqueda, orden y filtro “solo joyas ocultas” (1.253 títulos en el catálogo completo).

- **Datos financieros parciales:** solo el 21 % de las películas tiene ROI válido, y el ROI mide taquilla, no el valor dentro de la plataforma.

X-C. Oportunidades de mejora

- Incorporar eventos de uso (reproducción, abandono, sesión) y de suscripción para construir KPIs de retención y churn, y recalculer la tracción con reproducciones.
- Exigir más votos de referencia en series para que la calificación ponderada sea más estable.

- Publicar el dashboard en un servidor corporativo con actualización automática y control de acceso por rol; traducir los nombres de países que aún aparecen en inglés.
- Validar el diseño en pruebas de usabilidad con cada gerencia (tiempo en responder una pregunta) y evaluar las recomendaciones con pruebas A/B.

X-D. Decisiones de diseño reconsideradas

Descartamos la calificación simple por género porque los títulos con pocos votos generaban promedios engañosos, y

Tabla XVI
RECOMENDACIONES, EVIDENCIA, RESPONSABLE E INDICADOR DE SEGUIMIENTO

N.º	Recomendación	Evidencia (fuerza)	Responsable	Indicador y meta
1	Crear filas de “joyas ocultas” y una cuota de exposición para títulos bien evaluados con poca interacción; combinar popularidad y calificación ponderada en el ranking del recomendador.	Fig. 3, 4, 6, 7 (alta: patrón en ambos tipos)	Producto / UX	% del catálogo con al menos una reproducción en 90 días y % de reproducciones del top 10 %: medir la línea base y reducir la concentración en 12 meses, validado con prueba A/B (proxy actual: 86 % y 62 % en series).
2	Priorizar la adquisición de ciencia ficción y fantasía y acción y aventura (y misterio y crimen en series); revisar la inversión en talk show, reality y noticias después de confirmar su bajo consumo con datos propios.	Fig. 5 (media: proxy TMDB)	Contenidos y adquisiciones	Tracción calculada con reproducciones de las nuevas adquisiciones de al menos 1,0 (proxy actual en votos: 1,6–2,5 en géneros priorizados).
3	Ampliar y destacar el anime y el contenido japonés en ambos tipos, y el coreano en películas.	Fig. 8, 11; Tabla IX (alta en películas, media en series)	Contenidos / Marketing	Participación del contenido japonés en reproducciones y calificación interna de los títulos incorporados.
4	En coproducciones con ventana de cine, favorecer géneros de alto ROI (terror, animación, familiar) y controlar presupuestos en drama e historia.	Fig. 10 (media: solo taquilla)	Finanzas / Producción	ROI mediano de coproducciones frente a la referencia prepandemia (cerca de 100 %).
5	Instrumentar datos de reproducción, abandono, suscripción y dispositivo, e integrarlos al dashboard.	Secc. X (alta: brecha estructural)	Analítica / TI	Página de retención y churn operativa en 6 meses.

la reemplazamos por la ponderada. Descartamos también un índice de tracción común para películas y series, porque las películas concentran el 87 % de los votos y ocultaban a las series. El gráfico de idiomas del dashboard pasó de barras agrupadas a puntos para reducir la carga visual. Detectamos que el rojo se usaba a la vez para alertas y para resultados positivos, así que adoptamos un color de significado único con petróleo para las oportunidades. Por último, precisamos que la tracción se calcula sobre asignaciones título-género y no sobre títulos, y reemplazamos los textos con cifras fijas del dashboard por textos calculados.

XI. CONCLUSIONES Y RECOMENDACIONES

CRISP-DM · Fases 5 y 6: evaluación y despliegue (decisión)

XI-A. Conclusiones

1. **El problema principal es de descubrimiento, no de oferta.** El 10 % de los títulos concentra el 71 % (películas) y el 86 % (series) de los votos, y el 62 % de las series tiene menos de 10 votos.
2. **La oferta está desalineada con la interacción.** Ciencia ficción y fantasía y acción y aventura rinden hasta 2,5 veces su peso; talk show, reality y noticias, menos de 0,1.
3. **Hay calidad escondida.** Documental, música e historia (películas) y documental (series) están bien evaluados y son poco descubiertos, y popularidad y calidad apenas se relacionan (0,17–0,23).
4. **El anime japonés es la oportunidad de calidad más robusta;** el contenido coreano y el español destacan en películas.
5. **La calidad percibida no es el problema:** tiende a subir entre 2010 y 2024, con retrocesos y un posible sesgo de antigüedad.

XI-B. Recomendaciones

La Tabla XVI vincula cada recomendación con su evidencia, la fuerza de esa evidencia, su responsable y su indicador. Como los votos provienen de una comunidad externa, las metas se definen sobre datos propios de reproducción. Las cifras actuales se informan solo como línea base aproximada.

En síntesis, la mejor inversión inmediata de StreamView no es comprar más contenido, sino hacer visible el valor que ya tiene y medir, con datos propios, si eso aumenta la permanencia de sus suscriptores.

APÉNDICE A

TRAZABILIDAD CON LAS PAUTAS DE EVALUACIÓN

EP1 — Encargo	
Indicador	Dónde se evidencia
IE4 Percepción visual y jerarquía (14 %)	Secc. VII-A; títulos-mensaje en todas las figuras; Fig. 13
IE5 Atributos visuales (16 %)	Secc. VII-B, Tabla X
IE6 Comprensión y carga cognitiva (20 %)	Secc. VII-C; anotaciones en Fig. 9, 10
IE7 Tipo de gráfico según los datos (12 %)	Secc. VII-D, Tabla XI
IE9 Coherencia visual–audiencia–propósito (20 %)	Secc. IV, Tabla XIV
IE10 Narrativa visual (18 %)	Secc. VIII, Fig. 12, Tabla XII

EP2 — Presentación

Indicador	Dónde se evidencia (informe y presentación)
IE1 Audiencia y contexto (12 %)	Secc. IV, Tabla III; diapositiva 2
IE2 Propósito y problema de negocio (16 %)	Secc. I y IV-B; diapositiva 2
IE3 Estrategia de comunicación (22 %)	Secc. IV-C, Tabla IV; diapositiva 3
IE8 Justificación técnica de las representaciones (18 %)	Secc. VII, Tablas X y XI; diapositiva 11 y pie de cada gráfico
IE11 Recursos orales, escritos y visuales (14 %)	Secc. VIII-B y -C, Tablas XII y XIII; notas del orador
IE12 Conclusiones con evidencia (18 %)	Secc. XI, Tabla XVI; diapositiva 14

Metodología: CRISP-DM, Secc. III, Fig. 1, Tabla II; diapositiva 4.

APÉNDICE B

ESTRUCTURA Y EJECUCIÓN DEL PROYECTO

Carpetas: data/raw (fuentes), data/processed (tablas integradas), src/ (config, preparacion, metricas, graficos, graficos_paper), notebooks/ (01 integración y 02 análisis, ejecutados), dashboard/app.py, images/ y docs/ (este informe, presentación, guía de defensa y VALIDACION.md).
Ejecución: pip install -r requirements.txt;
python -m src.preparacion; python -m src.graficos_paper; streamlit run dashboard/app.py.

REFERENCIAS

- [1] The Movie Database (TMDB), “API documentation.” [En línea]. Disponible: <https://developer.themoviedb.org>
- [2] C. N. Knaflitz, *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Hoboken, NJ, USA: Wiley, 2015.
- [3] E. R. Tufte, *The Visual Display of Quantitative Information*, 2.^a ed. Cheshire, CT, USA: Graphics Press, 2001.
- [4] W. S. Cleveland y R. McGill, “Graphical perception: Theory, experimentation, and application to the development of graphical methods,” *J. Amer. Statist. Assoc.*, vol. 79, no. 387, pp. 531–554, 1984.
- [5] P. Chapman *et al.*, *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc., 2000.
- [6] S. Few, *Information Dashboard Design: The Effective Visual Communication of Data*. Sebastopol, CA, USA: O’Reilly, 2006.